

# 神经渲染--分层采样（Hierarchical Volume Sampling）机制与传统光追加速结构的关联性

根据论文第5.2节和附录描述的分层采样（Hierarchical Volume Sampling）机制，其与传统光线追踪加速结构的关联性可通过以下框架解读：

## 一、分层采样的核心思想（论文5.2节）

### 1. 问题背景：

- 均匀采样（Uniform Sampling）在空区域（如自由空间或被遮挡区域）效率低下。
- 传统体渲染需密集采样（每射线  $N_c = 64$  个点），但大量采样点对最终渲染贡献微乎其微。

### 2. 解决方案：

#### 两级网络架构：

- 粗网络（Coarse Network）**：均匀采样  $N_c$  个点，估计权重分布  $w_i$ （公式5）。

$$\hat{C}_c(\mathbf{r}) = \sum_{i=1}^{N_c} w_i c_i, \quad w_i = T_i(1 - \exp(-\sigma_i \delta_i)). \quad (5)$$

- 细网络（Fine Network）**：根据  $w_i$  构建概率密度函数（PDF），通过逆变换采样（Inverse Transform Sampling）抽取  $N_f$  个新样本点（偏向高权重区域）。

- 混合渲染**：联合  $N_c + N_f$  个点计算最终颜色  $\hat{C}_f(\mathbf{r})$ （公式3）。

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^N T_i(1 - \exp(-\sigma_i \delta_i)) c_i, \quad \text{where } T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right), \quad (3)$$

### 3. 物理本质：

- 权重  $w_i = T_i(1 - \exp(-\sigma_i \delta_i))$  表示射线段对像素颜色的贡献度。
- 通过  $\hat{w}_i = w_i / \sum w_j$  归一化得到概率密度函数（PDF），实现**重要性采样（Importance Sampling）**。

## 二、与传统光线追踪加速结构的共性

维度	传统光线追踪加速结构	NeRF分层采样
----	------------	----------

核心目标	减少无效光线求交计算	避免低贡献区域的密集采样
空间划分	基于场景几何（BVH/KD-Tree/包围盒）	基于辐射场权重分布（隐式概率建模）
动态适应性	静态场景预计算加速结构	实时优化采样分布（端到端训练）
关键思想	空间剔除（Culling）：跳过空区域	贡献加权采样：聚焦高重要性区域

共同哲学：通过预判"有贡献区域"减少无效计算。

### 三、与传统加速结构的核心差异

特性	传统光线追踪加速结构	NeRF分层采样
数据依赖	依赖显式几何（三角网格/SDF）	依赖神经辐射场 $\sigma, \mathbf{c}$ 预测
构建方式	预计算离线结构（不可微）	实时优化采样PDF（可微分）
处理对象	不透明表面（二值遮挡）	半透明介质（连续体密度）
采样粒度	物体/多边形级剔除	射线分段级重要性采样
实时性约束	需低延迟响应	容忍训练时高计算（渲染时采样点固定）

### 四、技术本质对比

#### 1. 传统加速结构：

- 空间索引：将几何空间划分为树状结构（KD-Tree/BVH），通过遍历跳过空节点。
- 示例：在渲染墙壁时跳过墙后的家具（遮挡剔除）。

#### 2. NeRF分层采样：

- 渲染驱动优化：利用粗网络生成权重函数  $w_i(t)$ ，对积分域重新参数化：

$$t_{\text{new}} \propto \int_{t_n}^t w_i(s) ds$$

- **效果示例：**在渲染透明物体（如水母）时，自动聚焦于密度突变区域（见论文图5中Lego模型的齿轮部分）。



### 3. NeRF的瓶颈：

分层采样仍要遍历所有粗样本点。当处理复杂遮挡时，Hierarchical NeRF等后续工作通过引入显式几何表示来进一步优化，这恰恰融合了传统图形学的空间划分思想。

### 五、实验验证（表2）

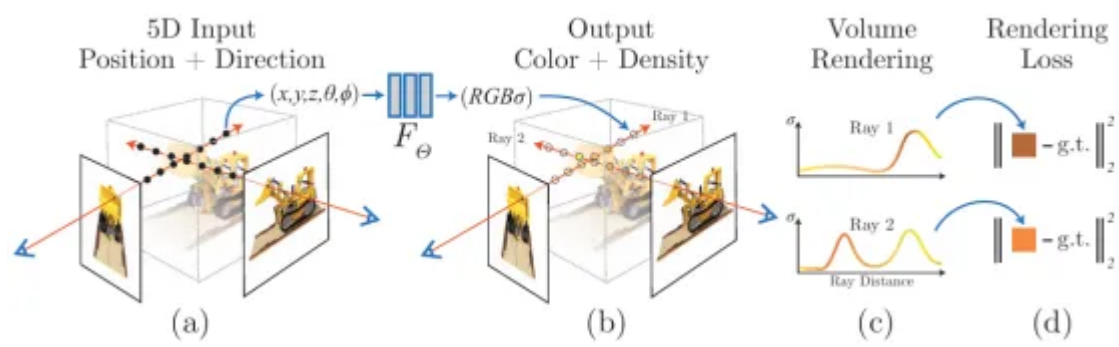
论文表2显示：

- **移除分层采样**（行4）：  $N_c = 256$ （无细网络） $\rightarrow$  PSNR下降0.95（31.01 $\rightarrow$ 30.06），SSIM下降0.009。
- **保留分层采样**（行9）：  $N_c = 64 + N_f = 128 \rightarrow$  性能显著优于均匀采样。

### 六、图形学视角总结

维度	传统光线追踪加速	NeRF分层采样
优化对象	求交计算量	体渲染积分采样量
数学工具	计算几何（空间划分）	概率统计（重要性采样）
可微性	不可微	可微（支撑端到端优化）
创新性	工程导向（硬件加速）	算法-渲染耦合（隐式场景建模）

**本质差异：**传统加速依赖**预定义几何结构**，而NeRF通过**辐射场权重分布**实现自适应性采样，二者分别解决"几何遮挡"与"介质贡献度"问题。分层采样的核心突破在于将**概率密度建模嵌入可微渲染流程**，形成动态优化闭环（见论文图2）。



总的来说，共性的核心在于“减少无效采样”的目标导向。差异则体现在三个方面：其一，传统加速依赖预构建数据结构，NeRF在训练过程中动态优化采样；其二，BVH等加速结构处理不透明表面，NeRF处理半透体素；其三，传统方法追求确定性剔除，NeRF的概率性采样会保留低贡献区域的基础样本。